

INTRODUÇÃO



Parabéns Candidato!

Por ter avançado para esta etapa! Este teste tem como objetivo avaliar suas habilidades práticas em engenharia de dados, abordando cenários reais que podem surgir na posição. Ao longo das questões, você será desafiado a demonstrar competências em:

- Banco de Dados (DBA)
- Pipelines de Dados
- CI/CD e DevOps
- Web Scraping
- Modelagem de Dados
- Cloud Computing (AWS)
- Data Governance e Segurança
- Data Lakes e Data Warehouses

REGRAS E ORIENTAÇÕES

- 
1. Você receberá o teste na **quarta-feira (08/01)** e deverá enviar suas respostas até **segunda-feira (13/01)**.
 2. Respostas devem ser organizadas em um repositório Git (público ou privado) com:
 - Scripts ou projetos.
 - Documentação explicando o raciocínio adotado.
 - Testes unitários para códigos relevantes.
 3. A entrega será avaliada pela originalidade, clareza e aderência às melhores práticas.
 4. Respostas prontas ou genéricas que não demonstrem pensamento crítico serão penalizadas.

QUESTÕES



Cenário de Banco de Dados (DBA)

Sua empresa possui um banco de dados PostgreSQL com uma tabela de logs que cresce em 1 milhão de linhas por dia. Atualmente, as consultas realizadas nessa tabela estão extremamente lentas.

Tarefas:

- 
- Proponha uma solução que otimize a performance para consultas de logs recentes (últimos 7 dias) sem degradar a consulta de logs antigos.
 - Explique como você implementaria:
 - Particionamento de tabelas.
 - Estratégia de indexação.
 - Backup e manutenção regular da tabela.

QUESTÕES



Pipeline de Dados

Você está criando um pipeline que deve:

1. Ler dados brutos de sensores IoT armazenados no S3.
2. Processar os dados em lotes (batch processing).
3. Carregar os resultados no Redshift para análises futuras..

2

Tarefas:

- Desenhe um diagrama arquitetural que represente o pipeline.
- Liste os principais desafios técnicos que você enfrentaria e como resolveria cada um.
- Escreva um script em Python que implemente a etapa de leitura do S3 e aplicação de uma transformação simples (ex.: cálculo de média de um campo).

CI/CD e DevOps

Sua equipe usa o Airflow para gerenciar pipelines de dados. Você precisa configurar um pipeline CI/CD que:

- Valide mudanças no código do Airflow antes do deploy.
- Realize testes automatizados em DAGs (Direcioned Acyclic Graphs).
- Envie alertas para o time se algo falhar durante o deploy.

3

Tarefas:

- Descreva o fluxo do pipeline CI/CD e ferramentas utilizadas.
- Crie um arquivo YAML básico para uma ferramenta CI/CD (ex.: GitHub Actions ou GitLab CI).
- Explique como garantir que o ambiente de produção esteja protegido contra deploys com falhas.

Modelagem de Dados

Um cliente deseja uma base de dados para gerenciar pedidos, clientes e produtos de uma loja virtual. Ele precisa saber:

1. Quais são os produtos mais vendidos.
2. O histórico de compras de cada cliente.
3. A evolução mensal do faturamento.

4

Tarefas:

- Modele o banco de dados, criando um esquema ER (Entidade-Relacionamento).
- Escreva scripts SQL para:
 - Retornar os produtos mais vendidos.
 - Listar o histórico de compras de um cliente específico.
 - Calcular o faturamento mensal.

Web Scraping

Você precisa monitorar os preços de produtos em um site de e-commerce que atualiza o layout com frequência e bloqueia bots de forma ativa.

5

Tarefas:

- Explique como configuraria um scraper resiliente para evitar bloqueios.
- Escreva um código básico que:
 - Realize o scraping de uma página fictícia com Python.
 - Detecte mudanças no layout (ex.: mudanças de tags HTML).

QUESTÕES



AWS e Infraestrutura

6

Sua empresa precisa processar grandes volumes de dados em tempo real e armazená-los para consultas futuras.

Tarefas:

- Descreva uma arquitetura AWS que inclua:
 - Ingestão em tempo real (ex.: Kinesis).
 - Processamento (ex.: Lambda ou Glue).
 - Armazenamento (ex.: S3 e Redshift).
- Explique como dimensionar essa arquitetura para lidar com picos de tráfego.

Monitoramento e Alertas

7

Um pipeline de dados apresenta falhas esporádicas que só são descobertas dias depois.

Tarefas:

- Proponha uma solução para implementar monitoramento e alertas em tempo real.
- Explique quais métricas monitorar (ex.: tempo de execução, volume de dados) e como configurar alertas no CloudWatch ou uma ferramenta equivalente.

Data Governance e Segurança

8

Sua empresa precisa garantir que os dados sensíveis armazenados em seu ambiente AWS estejam protegidos e em conformidade com regulamentações como LGPD ou GDPR.

Tarefas:

- Proponha uma estratégia para garantir:
 - Controle de acesso apropriado em S3 e Redshift.
 - Criptografia de dados em repouso e em trânsito.
 - Logs detalhados de acesso e auditoria.
- Explique como você verificaria se a empresa está em conformidade com regulamentações de proteção de dados.

Data Lakes e Data Warehouses

9

Sua empresa está implementando um **Data Lake** em S3 para armazenar dados brutos e um **Data Warehouse** em Redshift para análises estruturadas.

Tarefas:

- Explique como você estruturaria os dados no Data Lake para facilitar o consumo no Data Warehouse.
- Proponha uma política de gerenciamento do ciclo de vida dos dados no Data Lake, considerando arquivamento e exclusão de dados antigos.
- Escreva um script de exemplo que integre dados do Data Lake ao Data Warehouse usando Python e SQL.

QUESTÕES

**Entrega**

Certifique-se de incluir em sua entrega:

- **Documentação:** Explique claramente os passos seguidos e as decisões técnicas tomadas.
- **Scripts Funcionais:** Todo código deve ser funcional, com instruções claras de execução.
- **Testes:** Adicione testes para validar a integridade de seus códigos.